

Evaluating GPT-4o Zero-Shot Prompting

for Automated Behavior-Driven Development Acceptance Test Generation from Agile User Stories

Thành viên

Đào Thiên Thành
Lương Thiên Nhật
Thái Thành Long

Problem Statement

Khoảng trống công nghệ và phương pháp trong sinh BDD Acceptance Test bằng LLM

Background

BDD giúp tăng cộng tác giữa Business Analyst, Developer và Tester thông qua Acceptance Test viết bằng Gherkin (Given – When – Then).

Problem

Việc xây dựng BDD Acceptance Test thủ công tốn thời gian, phụ thuộc kinh nghiệm Tester và khó chuẩn hóa giữa các nhóm Agile.

Need

Cần sử dụng Large Language Models (LLMs) để tự động sinh Acceptance Test.

State of the Art — Karpurapu et al. (2024)

- Đánh giá GPT-3.5, GPT-4, Llama-2-13B, PaLM-2.
- Kết hợp Zero-shot Prompting và Few-shot Prompting.
- GPT-3.5 và GPT-4 đạt Validation Accuracy cao nhất.
- Few-shot tốt hơn Zero-shot.

Research Gap

GAP-T

Chưa đánh giá GPT-4o. Chưa biết GPT-4o Zero-Shot có thể sinh BDD Acceptance Test tốt hơn GPT-4 hay không.

GAP-M

Paper chỉ dùng Validation Accuracy và Syntax Errors; chưa dùng BLEU Score để đo tương đồng Gherkin.

Trọng tâm đề tài: GPT-4o Zero-Shot + BLEU Score + Syntax Correctness

Related Work (Evidence Table)

Tổng hợp paper, phương pháp, metric và kết quả chính

Paper	LLM / Phương pháp	Metric	Kết quả chính
Kapurapu et al. (2024)	GPT-3.5, GPT-4, Llama-2, PaLM-2	Validation Accuracy; Syntax	GPT-3.5 và GPT-4 tốt nhất; Few-shot vượt Zero-shot
Ferreira et al. (2025)	GPT-4 Turbo	Acceptance Test Quality	Đánh giá bằng chuyên gia
Fonseca et al. (2025)	AToMIC + LLM	Syntax Correctness	Khoảng 93% đúng cú pháp
Fernandes et al. (2025)	GPT-4o Mini, Gemini, Llama	Correctness; Consistency	So sánh nhiều LLM nhưng dataset nhỏ
Mathur et al. (2023)	GPT-3 + T5	Test Generation Accuracy	Tự động sinh test nhưng còn lỗi
Lafi et al. (2021)	NLP + CFG	Test Path Coverage	Coverage còn hạn chế
Guo et al. (2022)	WGAN-GP	Test Coverage	Cải thiện Unit Test Coverage
Utting et al. (2020)	Machine Learning	Test Identification	Nghiên cứu sơ bộ
Potuzak & Lipka (2023)	Literature Survey	Review	Tổng quan Automated Test Generation
Farooq et al. (2023)	Systematic Review	Qualitative Analysis	Tổng quan BDD

Kết luận 1

Nhiều nghiên cứu tập trung vào Machine Learning hoặc LLM để sinh Test Case.

Kết luận 2

GPT-3.5 và GPT-4 đạt kết quả tốt nhất; Few-shot thường hiệu quả hơn Zero-shot.

Kết luận 3

Metric chủ yếu là Validation Accuracy hoặc Syntax Errors.

Research Gap

Chưa có nghiên cứu đánh giá GPT-4o Zero-Shot bằng BLEU Score cho User Story → Gherkin.

Research Questions & Hypotheses

Câu hỏi nghiên cứu bám sát GPT-4o Zero-Shot Prompting

Main RQ: Liệu GPT-4o sử dụng Zero-Shot Prompting có sinh được Gherkin Acceptance Test từ User Stories đạt chất lượng ngữ nghĩa và cú pháp theo ngưỡng chuẩn hay không?

RQ1 — Semantic

GPT-4o Zero-Shot có đạt BLEU Score ≥ 0.70 so với Ground Truth không?

H01: $\mu\text{BLEU} < 0.70$

H11: $\mu\text{BLEU} \geq 0.70$

Test: One-Sample Wilcoxon Signed-Rank Test ($\alpha = 0.05$)

RQ2 — Syntax

GPT-4o Zero-Shot có đạt Syntax Correctness $\geq 90\%$ không?

H02: $p\text{syntax} < 0.90$

H12: $p\text{syntax} \geq 0.90$

Test: Binomial Exact Test ($\alpha = 0.05$)


RQ3 — Optional Extension

Nếu mở rộng thêm Few-Shot hoặc Chain-of-Thought, có sự khác biệt có ý nghĩa thống kê không?

Ngữ nghĩa: Paired Wilcoxon Test
Cú pháp: McNemar's Test

Experimental Pipeline

Quy trình thực nghiệm đã chỉnh sửa



Dataset

Mendeley Requirement Dataset + Public Agile User Stories (Parabol Blog); ~50 User Stories, đa miền.

Model Configuration

GPT-4o, Zero-Shot, Temperature=0, Top_p=1, Max Tokens=1024; 1 User Story → 1 Scenario.

Evaluation Metrics

BLEU Score ≥ 0.70 ; Syntax Correctness $\geq 90\%$; One-Sample Wilcoxon + Binomial Exact Test.

Dataset & Model Configuration

Cấu hình thực nghiệm để đảm bảo tính khách quan và khả năng tái lập

Dataset

Nguồn:

- Mendeley Requirement Dataset (User Stories)
- 45 User Story Examples (Parabol Blog)

Dataset thực nghiệm:

- Khoảng 50 Agile User Stories
- Đa miền: Healthcare, Banking, E-commerce, Education, ...
- Theo phương pháp của Karpurapu et al. (2024)

Model Configuration

- Model: GPT-4o (OpenAI)
- Prompting Strategy: Zero-Shot Prompting

Generation Parameters:

- Temperature = 0
- Top_p = 1
- Max_tokens = 1024

Evaluation Configuration

- Output: Gherkin Scenario (.feature)
- Metrics: BLEU Score (NLTK)
- Syntax Correctness: Gherkin-Lint + Behave Parser

Mục tiêu: kết quả sinh tất định và ổn định.

Output chính: Gherkin Scenario (.feature) được đánh giá bằng BLEU Score và kiểm tra cú pháp.

Statistical Plan

Bảng kiểm định thống kê

Mục tiêu	Ngưỡng	Phép kiểm	Rationale
Tương đồng ngữ nghĩa (RQ1)	≥ 0.70	One-sample Wilcoxon	So sánh trung vị BLEU với ngưỡng chất lượng
Cú pháp khả thi (RQ2)	$\geq 90\%$	Binomial Exact Test	Kiểm định tỷ lệ PASS/FAIL trên tập Gherkin
So sánh cặp ngữ nghĩa (RQ3)	Đối chứng	Paired Wilcoxon	So sánh BLEU giữa các kỹ thuật prompt
So sánh cặp cú pháp (RQ3)	Đối chứng	McNemar's Test	So sánh tỷ lệ cú pháp giữa các kỹ thuật

Kích cỡ hiệu ứng

Rank-Biserial Correlation cho các phép kiểm Wilcoxon.

Minh họa cú pháp

Tỷ lệ PASS/FAIL minh họa cho McNemar.

Threats to Validity

Các rủi ro nghiên cứu và hướng giảm thiểu cụ thể

Loại	Câu hỏi cốt lõi	Ví dụ Threat	Mitigation
Internal Validity	Kết quả có thực sự do intervention không?	Model version drift (cloud LLM); annotation bias	Pin version GPT-4o, log model version; double annotation + tính IAA Kappa ≥ 0.7
External Validity	Kết quả có generalize ra ngoài dataset không?	Dataset chỉ 1 domain, không đại diện	Dùng nhiều domain (Healthcare, Banking, E-commerce, Education); pilot + full run
Construct Validity	Metric có đo đúng cái muốn đo không?	BLEU không đo semantic meaning đầy đủ	Kết hợp BLEU với Syntax Correctness; báo cáo hạn chế metric trong §7
Conclusion Validity	Statistical power có đủ không?	N nhỏ, sub-group thiếu power	Tối thiểu 50 User Stories; pilot kiểm tra power; báo cáo effect size

Tư duy chính: kiểm soát model, dataset, metric và statistical power trước khi kết luận.

Timeline & Resources

Phân công vai trò, tài nguyên và kế hoạch tuần 5–10

Roles

Role	Trách nhiệm
PL (Project Lead)	Điều phối tiến độ, review, submit GV
DG (Data & Ground Truth)	Thu thập dataset, tạo ground truth, viết §3
LR (LLM Runner)	Setup API, chạy experiment, log output
MS (Metrics & Stats)	Implement metric, chạy statistical tests, tính effect size
RW (Report Writer)	Viết intro/conclusion/threats, tạo figures, format document

Tuần 7 là mốc pilot để kiểm tra pipeline trước khi chạy full run.

Resource Inventory

Resources

- ✓ Dataset: Mendeley + Parabol (đã tải thử, đa miền)
- ✓ API key: GPT-4o (free tier, log calls/day)
- ✓ Compute: Colab T4 / Kaggle P100 / local backup
- ⚠ Ground Truth: cần annotation thủ công (ước tính X giờ × Y người)

Timeline (Tuần 5–10)

Tuần	Hoạt động	Output
5–6	Viết proposal + chuẩn bị dataset	Draft §2–§7, data/raw/
7	Pilot run (10–20% sample)	pilot_ground_truth.csv, pilot_llm_output.csv
8	Full run	full_llm_output.csv, full_analysis.ipynb
9–10	Viết paper + present	Final report, figures

Expected Contribution

Đóng góp dự kiến của nghiên cứu

Khoa học (Academic)

- Bổ sung đánh giá GPT-4o Zero-Shot Prompting cho bài toán User Story → Gherkin Scenario.
- Đưa vào BLEU Score như một metric ngữ nghĩa mới, chưa từng được dùng trong các nghiên cứu trước.
- Cung cấp pipeline chuẩn hóa, có thể tái lập cho cộng đồng nghiên cứu.

Thực tiễn (Practical)

- Giảm thời gian viết Acceptance Test thủ công trong Agile.
- Chuẩn hóa cú pháp Gherkin, giảm lỗi syntax.
- Tăng khả năng áp dụng LLM vào quy trình BDD thực tế.

Thank you! • Q&A